Ярослав Сергаев

ML Engineer / ML Research Engineer

ИСП РАН

yaroslav.sergaev@gmail.com | github.com/adelardw | t.me/tohubohoo

ML-инженер с опытом исследований в области LLM и мультимодальных моделей. Разработал метод ускорения генерации LLM без потери качества (спекулятивное декодирование с диффузионным драфтером): на Qwen3-0.6B ускорение 1,44× против 1,35× у воспроизведённого бейзлайна. Разработал LLM-агента с гибридным поиском и LLM-ранжированием для СберБизнесОнлайн (∼3 тыс. WAU), ASR-модель на базе Whisper, заменившую решение вендора (экономия ∼5 млн руб./мес.), и CV-модели, воспроизведённые из статей и сжатые для edge-устройств.

Интересы: ускорение генерации LLM, VLM / VLA, RL для LLM, AI-агенты.
Целевые роли: ML Research Engineer / Research Scientist.

Опыт работы

ML Engineer (NLP, LLM), Сбер Май 2025 - н. в.

PyTorch | Transformers | LLM | Python | PySpark | FastAPI | Jenkins | OpenShift | Docker

- Разработал и запустил AI-агента на базе LLM в веб- и мобильной версиях СберБизнесОнлайн: **∼3 тыс. активных пользователей в неделю**, 9 мажорных релизов.
- Спроектировал архитектуру агента (SLA <30 с): собственная обвязка в виде API-инструментов, SGR (Schema-Guided Reasoning), система скиллов и саб-агент памяти; новые инструменты и скиллы подключаются через простые YAML/JSON-конфиги.
- Создал для агента двухэтапный гибридный поиск по справочникам (регионы, отрасли, ниши, адреса торговых точек): свой метод отбора кандидатов для каждого типа данных (fuzzy + TF-IDF для адресов и регионов, dense-эмбеддинги + TF-IDF для отраслей и ниш), затем LLM-ранжирование. На внутреннем бенчмарке **hit@1 вырос с 0,84 до 0,94, а MRR с 0,88 до 0,96**.
- Выстроил систему оценки качества агента: бенчмарки в формате LLM-as-a-Judge и Agent-as-a-Judge.
- Реализовал API-контракты и асинхронные сервисы на FastAPI с деплоем через Jenkins и OpenShift.

ML Engineer (DL, NLP, Audio), MTS Exolve (MTT) Ноябрь 2024 - май 2025

ASR (Whisper) | BERT | LLM | RAG | PyTorch | Python | Transformers | Deep Learning | MinIO

- Провёл полный цикл обучения ASR-модели на базе Whisper для транскрибации телефонных звонков с канальными помехами и несколькими спикерами: сбор, очистка и аугментация данных, полноценное обучение с QAT (FP8), оптимизация инференса. Итоговая модель (WER/CER ∼10-20%) заменила решение внешнего вендора, **сэкономив ∼5 млн руб. в месяц**.
- **Поднял throughput инференса LLM на инстанс с 1 до 4-5 RPS** (DeepSpeed) под целевую нагрузку 100 RPS.
- Дообучил Llama-3-8B с LoRA для ассистента сайта: SFT на парах из запросов и эталонных ответов, а также rejection sampling на лучших генерациях модели; добавил RAG с векторной БД Qdrant, что повысило качество ассистента по экспертной оценке.
- Сделал прототип выделения тем в транскрибированных диалогах: кластеризация эмбеддингов BERT методом K-Means.

ML Engineer (DL, CV), YADRO Январь 2024 - ноябрь 2024

Computer Vision | Deep Learning | ONNX | TFLite | PyTorch | Python | Transformers | Bash | Git

- Обучил модели детекции текста (TextSnake, DBNet) для edge-устройств, заменив исходный backbone ResNet-50 на MobileNetV3-Small: **в ∼25 раз меньше параметров backbone** (с 23,5 до 0,9 млн) и более чем в 10 раз меньше вычислений. Отдельно обучил модели классификации изображений на MobileNetV3.
- Построил на MobileCLIP двухбашенный zero-shot-классификатор изображений: классы задаются текстовыми эмбеддингами, поэтому новые добавляются без дообучения модели.
- Воспроизвёл модели из научных статей, сжал их и сконвертировал в ONNX и TFLite для инференса на устройстве, **сохранив более 90% исходного качества** на внутренних бенчмарках.
- Настроил пайплайны разметки данных (CVAT, Label Studio).

Проекты

FlowDraft 2026

Статья принята в сборник SMILES School Projects Proceedings (SSPP) 2026 | Skoltech Applied AI Center

Метод спекулятивного декодирования без потери качества: диффузионный (flow-map) драфтер встроен в замороженную LLM и обучается на собственной цепочке уточнений. На Qwen3-0.6B метод превосходит воспроизведённый Orthrus: 2,58 против 2,20 принятых токенов за цикл и ускорение 1,44× против 1,35×.

github.com/adelardw/FlowDraft

mdfr-rppgfau 2026

Соавтор статьи, прошедшей первый этап рецензирования на AAAI 2027

Мультимодальная детекция дипфейков: FAU (Swin-T + ME-GraphAU) и rPPG (DeepFakesON-Phys) со слиянием через Q-Former. Метрики оказались завышены: 34% тестовых клипов были аугментациями обучающих, модель могла запоминать актёров. Чтобы она училась на артефактах подделки, добавил кроп лиц (MTCNN), контрастивное обучение с memory bank и разбиение без пересечения лиц по исходным клипам и кластерам FaceNet. На 53 отложенных видео других генераторов: accuracy 0,815, AUROC 0,844.

github.com/adelardw/mdfr-rppgfau

SelfExtensionAgent (SEA) 2026

Пет-проект

Саморасширяющийся агентный харнесс в стиле Claude Code на LangGraph: если для задачи не хватает инструмента, агент сам пишет его на Python, проверяет на безопасность и работоспособность (статический анализ, LLM-ревью, smoke-тест в песочнице) и регистрирует. Более 70 инструментов, долговременная память, MCP, подтверждение действий человеком, поддержка OpenAI-совместимых API и Ollama.

github.com/adelardw/SelfExtensionAgent

AudioDenoisingNet 2025

Магистерская диссертация, НИУ ВШЭ

Компактная модель шумоподавления речи: U-Net (1,85 млн параметров) на STFT-спектрограммах с коррекцией фазы; на CPU ноутбука обрабатывает 8 с аудио за ∼1,2 с (RTF ≈ 0,15). Устранил артефакт ISTFT на краях сигнала без повторного обучения: SI-SDR на VoiceBank+DEMAND вырос с 5,2 до 9,5 дБ.

github.com/adelardw/AudioDenoisingNet

Образование

Аспирантура, компьютерные науки 2025 - 2028 (ожид.)

Институт системного программирования им. В. П. Иванникова РАН (ИСП РАН), Москва

Тема исследований: мультимодальные языковые модели.

Магистратура, машинное обучение и анализ данных 2023 - 2025

НИУ ВШЭ, Санкт-Петербург

Бакалавриат, теоретическая физика 2019 - 2023

ННГУ им. Н. И. Лобачевского, Нижний Новгород

Исследовательская программа SMILES 2026

Skoltech Applied AI Center

Summer of Machine Learning at Skoltech; в рамках программы разработал FlowDraft.

Курсы по NLP, CV и ML

Школа анализа данных Яндекса (ШАД)

Технические навыки

Языки	Python, Bash
Фреймворки	PyTorch, PyTorch Lightning, Hugging Face Transformers, PEFT, TRL
Области	RL, NLP, MLLM (VLM / LLM / VLA), временные ряды, RecSys, AI-агенты
LLM и VLM	дообучение (LoRA / PEFT), RAG, слияние модальностей (Q-Former)
RL и алайнмент	RL, RLHF, DPO, GRPO, RLVR, RLAIF
AI-агенты	LangChain, LangGraph, MCP (FastMCP), Agent-as-a-Judge, LLM-as-a-Judge
Поиск и ранжирование	BERT, Qdrant, FAISS, TF-IDF, fuzzy matching, LLM-ранжирование
Оптимизация моделей	квантизация, дистилляция, прунинг, спекулятивное декодирование vLLM, DeepSpeed, AutoAWQ, TorchAO, ONNX, TFLite, TorchScript/JIT
CV и аудио	OpenCV, torchvision, torchaudio
Данные	NumPy, Pandas, PySpark, Redis
MLOps и бэкенд	Docker, MLflow, Optuna, Git, CI/CD (GitLab, Jenkins), FastAPI

Достижения и языки

Хакатоны	Топ-3 на ML-хакатоне «Газпрома» (кейс цифрового двойника)
Языки	русский (родной); английский B2 (научные и технические тексты)